

# Aula – Econometria

Cláudio R. Lucinda

FEA/USP

2020



# Objetivos da Aula

- 1 Estimação de Sistemas de Equações
  - OLS
  - SUR
  - Mínimos Quadrados Generalizados Factíveis
  - Mínimos Quadrados a Dois Estágios
  - Mínimos Quadrados a Três Estágios
  - GMM em Sistema



# Estimação de Sistemas de Equações

- A estimação de sistemas de equações de demanda, qualquer que seja a especificação, possui uma estrutura comum:

$$\mathbf{y}_1 = \mathbf{X}_1(\beta_1) + \epsilon_1$$

$$\mathbf{y}_2 = \mathbf{X}_2(\beta_2) + \epsilon_2$$

•  
•  
•

$$\mathbf{y}_M = \mathbf{X}_M(\beta_M) + \epsilon_M$$

- Existem  $M$  equações, em que as variáveis em cada uma delas possuem  $T$  observações.
- Escolhemos por denotar a parte independente das equações de demanda por  $\mathbf{X}(\beta)$  para enfatizar o fato que, na maior parte das vezes, estaremos lidando com uma função não linear envolvendo os regressores  $\mathbf{X}$  e os coeficientes  $\beta$ .
  - Além disso, esta função é diferente – envolvendo diferentes coeficientes, por exemplo – em cada uma das equações.



# Sistemas de Equação

- Iremos, neste texto, enfatizar a similaridade das técnicas de estimação e a sua base comum no Método Generalizado dos Momentos.
- Para começarmos, vamos introduzir uma notação adicional.
  - Seja  $\mathbf{y}_\bullet$  o vetor de dimensão  $MT \times 1$  obtido a partir da “vetorização” dos pequenos vetores  $\mathbf{y}_i$ .
  - Da mesma forma, iremos denotar  $\mathbf{X}_\bullet(\beta)$  o vetor obtido a partir do “empilhamento” dos lados direitos da igualdade,
  - $\epsilon_\bullet$  o vetor obtido a partir do “empilhamento” dos resíduos de cada uma das regressões.
- Desta forma, o que vimos no slide anterior fica sendo igual a:

$$\mathbf{y}_\bullet = \mathbf{X}_\bullet(\beta) + \epsilon_\bullet$$



## OLS

- Neste caso, podemos escrever a  $i$ -ésima equação do sistema da seguinte forma:

$$\begin{aligned} \mathbf{y}_i &= \mathbf{X}_i(\beta) + \epsilon_i \\ E(\epsilon_i \epsilon_i^T) &= \sigma_{ii} \mathbf{I}_T \end{aligned}$$

- Em que  $\mathbf{I}_T$  denota a matriz identidade de dimensão  $T \times T$ . Além disso, precisamos da seguinte condição:

$$E(\epsilon_i \epsilon_j^T) = \mathbf{0}, \forall j \neq i$$

- Em que  $\mathbf{0}$  denota a matriz zero de dimensão  $T \times T$ . Neste caso, podemos construir a matriz variância-covariância do sistema:

$$E(\epsilon_{\bullet} \epsilon_{\bullet}^T) = \mathbf{V} = \begin{bmatrix} \sigma_{11} \mathbf{I} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \sigma_{22} \mathbf{I} & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \sigma_{MM} \mathbf{I} \end{bmatrix}$$



# OLS (cont.):

- Neste caso, podemos estimar os coeficientes do sistema se estimarmos equação por equação por OLS, caso não tivéssemos restrições dos coeficientes entre as equações.
- A estimação se daria por meio da minimização da função critério – que no caso seria a soma dos quadrados dos resíduos, ponderada pela inversa da matriz de variância-covariância dos resíduos:

$$SSR_{\bullet} = (\mathbf{y}_{\bullet} - \mathbf{X}_{\bullet}(\beta))^T (\Sigma^{-1} \otimes \mathbf{I})(\mathbf{y}_{\bullet} - \mathbf{X}_{\bullet}(\beta))$$

- Em que  $\Sigma$  representa a matriz de variância-covariância dos resíduos, que no caso em questão possuem a seguinte forma:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1M} = \mathbf{0} \\ \vdots & \ddots & \vdots \\ \sigma_{M1} = \mathbf{0} & \cdots & \sigma_{MM} \end{bmatrix}$$



## OLS (III):

- Geralmente são estimados os membros desta matriz com os resíduos da regressão, ou seja -  $\sigma_{11} = \epsilon_1^T \epsilon_1$  Com isto, temos como estimativa de variância de  $\beta$ :

$$\widehat{Var}(\beta) = (\mathbf{X} \mathbf{d}_{\bullet}^T(\beta) (\boldsymbol{\Sigma}^{-1} \otimes \mathbf{I}) \mathbf{X} \mathbf{d}_{\bullet}(\beta))^{-1}$$

- Em que  $\mathbf{X} \mathbf{d}_{\bullet}(\beta)$  é uma matriz de derivadas parciais de  $\mathbf{X}_{\bullet}(\beta)$  com relação a cada um dos coeficientes, e  $\otimes$  denota o Produto Kronecker.
  - Se estivéssemos com equações lineares nos coeficientes,  $\mathbf{X} \mathbf{d}_{\bullet}(\beta) = \mathbf{X}_{\bullet}$ .



## SUR

- A diferença entre este método e o anterior reside na estrutura de correlação entre os erros das equações.
- A idéia desta técnica é que, mesmo que tenhamos as variáveis independentes e as variáveis dependentes sendo completamente diferentes entre as equações, a correlação entre os resíduos da regressão pode ser diferente, de forma que estimar isto por Mínimos Quadrados Ordinários não dá certo.
  - Daí o nome de *Seemingly Unrelated Regressions* (Regressões Aparentemente Não Relacionadas)
- Neste caso, temos que a matriz  $\Sigma$  tem a seguinte estrutura:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1M} \\ \vdots & \ddots & \vdots \\ \sigma_{M1} & \cdots & \sigma_{MM} \end{bmatrix}$$





## SUR (Cont.)

- O que nos dá a seguinte matriz de variância-covariância dos resíduos empilhados:

$$E(\epsilon_{\bullet}\epsilon_{\bullet}^T) = \mathbf{V} = \mathbf{\Sigma} \otimes \mathbf{I}_T$$

Temos, neste caso, a mesma função critério a ser minimizada:

$$SSR_{\bullet} = (\mathbf{y}_{\bullet} - \mathbf{X}_{\bullet}(\beta))^T (\mathbf{\Sigma}^{-1} \otimes \mathbf{I})(\mathbf{y}_{\bullet} - \mathbf{X}_{\bullet}(\beta))$$

- A matriz de variância-covariância dos coeficientes neste caso é similar também:

$$\widehat{Var}(\beta) = (\mathbf{X}\mathbf{d}^T_{\bullet}(\beta)(\mathbf{\Sigma}^{-1} \otimes \mathbf{I})\mathbf{X}\mathbf{d}_{\bullet}(\beta))^{-1}$$



# FGLS System

- Neste caso, a estrutura é bastante similar, o que mudaremos é a forma pela qual a nossa já queria matriz  $\Sigma$  é calculada.
- Neste caso, teríamos uma situação em que cada um dos elementos da matriz  $\Sigma$  seria calculada por um método como o de Newey-West, em que  $\sigma_{ij}$  seria uma soma ponderada das variâncias, das covariâncias entre os resíduos entre  $t$  e  $t - 1$ ,  $t$  e  $t - 2$ , e assim por diante.
- Mais especificamente:

$$\sigma_{ij} = \sum_{j=-n+1}^{n-1} k(x) \times \hat{\Gamma}_{ij}$$

$$k(x) = \begin{cases} 1 - |x| & \text{para } |x| \leq 1 \\ 0 & \text{c.c.} \end{cases}$$

$$\hat{\Gamma}_{ij} = \epsilon_i \epsilon_{i(-j)}$$

$$x = \frac{j}{q}$$



## Aula – Econometria

- └─ Estimação de Sistemas de Equações
  - └─ Mínimos Quadrados Generalizados Factíveis
    - └─ FGLS System

- Neste caso, a estrutura é bastante similar, o que mudaremos é a forma pela qual a nossa  $\Sigma$  queria matriz  $\Sigma$  é calculada.
- Neste caso, teríamos uma situação em que cada um dos elementos da matriz  $\Sigma$  seria calculada por um método como o de Newey-West, em que  $\sigma_{ij}$  seria uma soma ponderada das variâncias, das covariâncias entre os resíduos entre  $t$  e  $t-1$ ,  $t$  e  $t-2$ , e assim por diante.
- Mais especificamente:

$$\sigma_{ij} = \sum_{s=-q}^{s=q} k(s) \times r_{ij}$$

$$k(s) = \begin{cases} 1 - |s| & \text{para } |s| \leq 1 \\ 0 & \text{c.a.} \end{cases}$$

$$r_{ij} = r_i r_{j-1}$$

$$q = \frac{L}{q}$$

1. Sendo que  $q$  é a chamada largura de banda *bandwidth*

# TSLs

- Neste caso, temos uma diferença em relação aos casos anteriores, em que temos entre os regressores uma – ou mais de uma – variável que se considera como sendo determinada conjuntamente com a variável dependente.
- Vamos começar supondo um modelo linear, em que a  $i$ -ésima equação possui a seguinte forma:

$$\mathbf{y}_i = \mathbf{z}_i\delta + \epsilon_i$$

- Em que  $\mathbf{z}_i = [\mathbf{Y}_i | \mathbf{x}_i]$ . Ou seja, juntamos as variáveis que são consideradas como endógenas ( $\mathbf{Y}_i$ ) e as que são consideradas como exógenas ( $\mathbf{x}_i$ ).



# TSLS (III):

- Supondo que  $\mathbf{x}_i$  inclua todas as variáveis exógenas e que estas variáveis exógenas sejam suficientes para o atendimento das condições de posto e condições de ordem do sistema de equações, temos que podemos obter a estimativa dos coeficientes do sistema por meio das chamadas “condições de ortogonalidade”:

$$\mathbf{m}(\delta) = \frac{1}{T} \sum_{t=1}^T \mathbf{x}_t(\mathbf{y}_i - \mathbf{z}_i\delta)$$

- A idéia é escolher os coeficientes de forma a minimizar este valor para torná-lo o mais próximo de zero possível.
- Supondo que tenhamos mais instrumentos do que variáveis endógenas no sistema – ou seja, ele é sobre-identificado – este sistema nunca dá exatamente zero.



# TSLS (Cont.):

- Para resolver isso, geralmente se escolhe o vetor de coeficientes que minimiza a seguinte função objetivo:

$$q = \mathbf{m}(\delta)^T W^{-1} \mathbf{m}(\delta)$$

Na verdade isto aqui é uma forma quadrática, com uma ponderação dada pela variância dos resíduos. Se os resíduos da equação são homoscedásticos e não autocorrelacionados, a matriz  $W = (\mathbf{X}^T \mathbf{X})$  nos dá os resultados do Método dos Mínimos Quadrados a Dois Estágios:

$$\begin{aligned} \delta_{TSLS} &= (\mathbf{X}^T (\mathbf{I} - \mathbf{M}_X) \mathbf{Z})^{-1} \mathbf{X}^T (\mathbf{I} - \mathbf{M}_X) \mathbf{y} \\ (\mathbf{I} - \mathbf{M}_X) &= \mathbf{X}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X} \end{aligned}$$



## MQ3E

- Vamos agora começar a discutir os métodos de estimação que consideram a informação de todos os resíduos do sistema. O primeiro destes modelos é o método dos Mínimos Quadrados a Três Estágios, em que supomos que a estrutura de covariância entre os resíduos das equações é a seguinte:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1M} \\ \vdots & \ddots & \vdots \\ \sigma_{M1} & \cdots & \sigma_{MM} \end{bmatrix}$$

- O que nos dá a seguinte matriz de variância-covariância dos resíduos empilhados:

$$E(\epsilon_{\bullet}\epsilon_{\bullet}^T) = \mathbf{V} = \Sigma \otimes \mathbf{I}_T$$



## MQ3E (Cont.)

- Com esta estrutura de resíduos, podemos calcular os estimadores de Mínimos Quadrados a Três Estágios da seguinte forma:

$$\begin{aligned}\beta_{3SLS} &= (\hat{\mathbf{Z}}_{\bullet}(\mathbf{\Sigma}^{-1} \otimes \mathbf{I})\hat{\mathbf{Z}}_{\bullet})^{-1}\hat{\mathbf{Z}}_{\bullet}(\mathbf{\Sigma}^{-1} \otimes \mathbf{I})\mathbf{y} \\ \hat{\mathbf{Z}} &= \mathbf{X}^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}\mathbf{Z}\end{aligned}$$

- Neste caso, a matriz  $\mathbf{\Sigma}$  é calculada com os resíduos de Mínimos Quadrados a Dois Estágios calculados equação por equação. Na verdade esta é uma aplicação do caso mais geral do Método Generalizado dos Momentos com equações não-lineares, que é o que veremos mais adiante.





# GMM em Sistema

- Finalmente, passamos ao método mais amplo de todos, o Método Generalizado dos Momentos para o sistema de equações. a idéia neste caso começa com o seguinte conjunto de condições de ortogonalidade para cada uma das equações do sistema:

$$\mathbf{m}_i(\delta) = \mathbf{Z}^T(\mathbf{Y}_i - \mathbf{X}_i(\beta))$$

- Em que  $\mathbf{Z}$  denota o conjunto de instrumentos utilizado. A partir destas condições de ortogonalidade, podemos definir a seguinte função a ser minimizada:

$$q = \sum_{i=1}^M \sum_{j=1}^M ((\mathbf{Y}_i - \mathbf{X}_i(\beta))^T \mathbf{Z})(\mathbf{W})^{ij} (\mathbf{Z}^T (\mathbf{Y}_i - \mathbf{X}_i(\beta)))$$

- Nesta equação, o único termo ainda não visto é o  $(\mathbf{W})^{ij}$ , que seria a inversa da covariância entre os momentos da equação  $i$  e os momentos da equação  $j$ .



# GMM em Sistema (Cont.)

- Ou ainda, podemos abrir o sistema da seguinte forma:

$$q = \begin{bmatrix} (\mathbf{y}_1 - \mathbf{X}_1(\beta))^T \mathbf{Z} \\ \vdots \\ (\mathbf{y}_M - \mathbf{X}_M(\beta))^T \mathbf{Z} \\ \mathbf{Z}^T (\mathbf{y}_1 - \mathbf{X}_1(\beta)) \\ \vdots \\ \mathbf{Z}^T (\mathbf{y}_M - \mathbf{X}_M(\beta)) \end{bmatrix}^T \begin{bmatrix} \sigma_{11}(\mathbf{Z}^T \mathbf{Z}) & \cdots & \sigma_{1M}(\mathbf{Z}^T \mathbf{Z}) \\ \vdots & \ddots & \vdots \\ \sigma_{M1}(\mathbf{Z}^T \mathbf{Z}) & \cdots & \sigma_{MM}(\mathbf{Z}^T \mathbf{Z}) \end{bmatrix}$$

- Estamos supondo aqui que os resíduos em cada uma das equações são homocedásticos e não autocorrelacionados.



- └─ Estimação de Sistemas de Equações
  - └─ GMM em Sistema
  - └─ GMM em Sistema (Cont.)

• Ou ainda, podemos abrir o sistema da seguinte forma:

$$q = \begin{bmatrix} (y_1 - \mathbf{X}_1(\beta))^T \mathbf{Z} \\ \vdots \\ (y_M - \mathbf{X}_M(\beta))^T \mathbf{Z} \\ \mathbf{Z}^T (y_1 - \mathbf{X}_1(\beta)) \\ \vdots \\ \mathbf{Z}^T (y_M - \mathbf{X}_M(\beta)) \end{bmatrix}^T \begin{bmatrix} \sigma_{11}(\mathbf{Z}^T \mathbf{Z}) & \cdots & \sigma_{1M}(\mathbf{Z}^T \mathbf{Z}) \\ \vdots & \ddots & \vdots \\ \sigma_{M1}(\mathbf{Z}^T \mathbf{Z}) & \cdots & \sigma_{MM}(\mathbf{Z}^T \mathbf{Z}) \end{bmatrix}$$

• Estamos supondo aqui que os resíduos em cada uma das equações são homoscedásticos e não autocorrelacionados.

1. Em geral, ele é mais vantajoso do que o Método dos Mínimos Quadrados a Três Estágios porque tem ganhos de eficiência na presença de correlação e heterocedasticidade (a matriz do meio pode ser ajustada com o uso do estimador de Newey-West para dar estimativas robustas).