

Modelos Dinâmicos I:  
"Optimal Replacement of GMC Bus Engines: An  
Empirical Model of Harold Zurcher" por John Rust

June 10, 2020

# Outline

## 1 Introduction

## 2 Base de Dados

## 3 Modelo

- Modelo com solução com forma funcional fechada
- Modelo estrutural sem forma funcional fechada

## 4 Estimando o modelo

## 5 Resultados

- Estimação de modelos de otimização dinâmica.
- Modelo regenerativo de decisão ótima de parada para descrever Harold Zurcher.
- Trade off entre minimizar custo de manutenção dos ônibus da frota e o custo de falhas em serviço.

- Zurcher: superintendente de manutenção da frota de ônibus de Madisin, Wisconsin, EUA.
- Abordagem botton-up para modelar investimento.
- Método: nested fixed point algorithm para estimação.

- Frota de ônibus de Madison, Wisconsin, EUA.
- Dados de 162 ônibus, dezembro/1975 à maio/1985.
- Para cada ônibus observa todo mês:
  - ① milhagem
  - ② diário de manutenção. considera retifica do motor somente.

- Tabela 1: frota de ônibus. Usa grupos 1-4 na estimação.
- Tabela 2a: sub-amostra com pelo menos uma retífica (viés de seleção).
- Tabela 2b: sub-amostra com nenhuma retífica (censura).
- Figura 1: chave do problema.
- Tabela 3: custos de retífica.

# Pausa para reflexão

- O que o artigo quer? Descreva o problema a ser resolvido em uma frase.
- O que os dados dizem sobre isso? (ver fig. 1)
- Como você estimaria isso da maneira mais simples possível?
- Essa estimação estaria contemplando todos os aspectos do problema? Se não, qual seria o viés?

- variável de controle

$$i_t = \begin{cases} 1, & \text{se houve retífica} \\ 0, & \text{caso contrário} \end{cases}$$

- $x_t \rightarrow$  milhagem em  $t$
- $\{i_t, x_t\} \rightarrow$  processo estocástico controlado
- Odômetro zera quando motor é retificado.



# Modelo com solução com forma funcional fechada

$c(x_t, \theta_1) \rightarrow$  custo operacional

Todo mês Zurcher decide entre:

- ① manutenção regular com custo  $c(x_t, \theta_1)$
- ② substitui o motor velho por um novo. Vende o velho por  $\underline{P}$ , compra um novo por  $\overline{P}$ , e tem custo operacional  $c(0, \theta_1)$ .

# Modelo com solução com forma funcional fechada

- Utilidade a cada período:

$$u(x_t, i_t) = \begin{cases} -c(x_t, \theta_1), & i_t = 0 \\ -[\bar{P} - \underline{P} + c(0, \theta_1)], & i_t = 1 \end{cases}$$

- Milhagem acumulada a cada mês por um ônibus é distribuído exponencialmente com parâmetro  $\theta_2$ :

$$p(x_{t+1}|x_t, i_t, \theta_2) = \begin{cases} \theta_2 \exp\{\theta_2(x_{t+1} - x_t)\}, & \text{se } i_t = 0 \text{ e } x_{t+1} \geq x_t \\ \theta_2 \exp\{\theta_2(x_{t+1})\}, & \text{se } i_t = 1 \text{ e } x_{t+1} \geq 0 \\ 0, & \text{nos outros casos} \end{cases}$$

# Optimal Stopping Problem

- A regra ótima de quando parar é a solução do seguinte problema:

$$V_{\theta}(x) = \sup_{\Pi} E\left\{\sum_{j=t}^{\infty} \beta^{j-t} u(x_j, f_j, \theta_1) | x_t\right\}$$

Onde  $\Pi$  é uma sequência infinita de regras de decisão

$$\Pi = \{f_t, f_t + 1, \dots\}.$$

- $V_{\theta}(x)$  é a função valor e é a única solução da equação de Bellman:

$$V_{\theta}(x_t) = \max_{i_t} u(x_t, i_t, \theta_1) + \beta EV_{\theta}(x_t, i_t)\}$$

onde

$$EV_{\theta}(x_t, i_t) = \int_0^{\infty} V_{\theta}(y) p(dy | x_t, i_t, \theta_2)$$

# Optimal Stopping Problem

- Rust prova que a solução ótima é uma regra markoviana estacionária do tipo:

$$i_t = f(x_t, \theta) = \begin{cases} 1, & \text{se } x_t > \gamma(\theta) \\ 0, & \text{se } x_t \leq \gamma(\theta) \end{cases}$$

- $\gamma(\theta)$  : valor crítico da milhagem. (ver figura 1. qual o problema?)

# Modelo estrutural sem forma funcional fechada

- Utilidade:  $u(x_t, i_t, \theta_1) + \epsilon_t(i)$
- probabilidade de transição entre estados:  $p(x_{t+1}, \epsilon_{t+1} | x_t, \epsilon_t, i_t, \theta_2, \theta_3)$
- Equação de Bellman:

$$V_\theta(x_t) = \max_{i_t} \{u(x_t, i_t, \theta_1) + \epsilon_t(i) + \beta EV_\theta(x_t, \epsilon_t, i_t)\}$$

onde

$$EV_\theta(x_t, i_t) = \int_0^\infty V_\theta(y, \eta) p(dy, d\eta | x_t, \epsilon_t, i_t, \theta_2, \theta_3)$$

# A solução do modelo e a integral da esperança

- CPO de eq. de Bellman fornece a solução ótima.
- Regra de decisão estacionária:  $i_t = f(x_t, \epsilon_t, \theta)$
- Problema:  $\epsilon_t$  aparece em  $EV_\theta$ . Logo, é necessário calcular a esperança de integrando  $\epsilon$ . Temos então que integrar  $V_\theta$  usando  $p(x_{t+1}, \epsilon_{t+1} | x_t, \epsilon_t, i_t, \theta_2, \theta_3)$ . Feito isto, temos que integrar a equação de Bellman para achar a política ótima  $i_t = f(x_t, \epsilon_t, \theta)$ .
- **Note o seguinte:  $i(x, \epsilon, \theta)$ . Logo, existem probabilidades associadas a cada possível decisão. Em econometria não chamamos de política ótima, mas de conditional choice probabilities.**

# Hipótese 1: independência condicional

- $p(x_{t+1}, \epsilon_{t+1} | x_t, \epsilon_t, i_t, \theta_2, \theta_3) = q(\epsilon_{t+1} | x_{t+1}, \theta_2) p(x_{t+1} | x_t, i_t, \theta_3)$
- $x_{t+1}$  is a sufficient statistic for  $\epsilon_{t+1}$
- $x_{t+1}$  depende somente de  $x_t$ , e não de  $\epsilon_t$

## Hipótese 2: extreme value distribution

- $q(\epsilon|x, \theta)$  segue uma distribuição extreme value type I.
- E voltamos pro logit! A probabilidade do agente escolher  $i = 1$ ,  $P(i = 1|x, \theta)$  é:

$$P(u(x_t, 1, \theta_1) + \epsilon_t(1) + \beta EV_\theta(x_t, \epsilon_t, 1) \geq u(x_t, 0, \theta_1) + \epsilon_t(0) + \beta EV_\theta(x_t, \epsilon_t, 0)) =$$

$$P(\epsilon_t(1) - \epsilon_t(0) \geq u(x_t, 0, \theta_1) - u(x_t, 1, \theta_1) + \beta EV_\theta(x_t, \epsilon_t, 0) - \beta EV_\theta(x_t, \epsilon_t, 1))$$

- Como  $\epsilon$  é distribuído como valor extremo, a solução da integral para calcular essa probabilidade, tem a forma funcional do logit.



# Conditional choice probability

- Conditional choice probability:

$$P(i = 1|x, \theta) = \frac{\exp\{u(x_t, 1, \theta_1) + \beta EV_\theta(x_t, \epsilon_t, 1)\}}{\sum_j \exp\{u(x_t, j, \theta_1) + \beta EV_\theta(x_t, \epsilon_t, j)\}}$$

onde

$$EV_\theta(x, i) = \int_y \log \sum_j \exp[u(y, j, \theta_1) + \beta EV_\theta(y, j)] p(dy|x, i, \theta_3)$$

- Esse termo é chamado de excedente social, e também é conhecido como log-sum.
- Paralelo com o nested logit.  $EV_\theta(x_t, \epsilon_t, i)$  é o inclusive value do nested logit.

- A função verossimilhança para um ônibus é dada por

$$l(x_1, \dots, x_T, i_1, \dots, i_T | x_0, i_0, \theta) = \prod_{t=1}^T P(i_t | x_t, \theta) p(x_t | x_{t-1}, i_{t-1}, \theta_3)$$

# Algoritmo: nested fixed point

- 1 Dado um  $\theta$ , itera a equação do excedente social para achar o ponto fixo  $EV_\theta$  (algoritmo interno)
- 2 Dado  $EV_\theta$ , algoritmo de busca acha o  $\theta$  que maximiza a função verossimilhança (algoritmo externo)

# Estimando o modelo - parametrizando

- utilidade:

$$u(x_t, i_t, \theta_1) + \epsilon_t(i) = \begin{cases} -c(x_t, \theta_1) + \epsilon_t(0), & \text{se } i_t = 0 \\ -RC - c(0, \theta_1) + \epsilon_t(1), & \text{se } i_t = 1 \end{cases}$$

- probabilidade de transição

$$p(x_{t+1}|x_t, i_t, \theta_3) = \begin{cases} g(x_{t+1} - x_t, \theta_3), & \text{se } i_t = 0 \\ g(x_{t+1} - 0, \theta_3), & \text{se } i_t = 1 \end{cases}$$

# Estimando o modelo - parametrizando

- Objetivo é estimar  $\beta, \theta_1, \theta_3, RC$
- ❶ discretiza o espaço de estado  $x_t$  (milhagem): 90 intervalos de 5000 milhas.
- ❷  $g(\cdot)$  é uma distribuição multinomial sobre 1, 2, 3, que correspondem aos aumentos de milhas  $[0, 5000]$ ,  $[5000, 10000)$  e  $[10000, \infty)$ .  
 $f(x_1, \dots, x_n) = p_1^{x_1} \dots p_n^{x_n}$
- ❸ Custo operacional

$$c(x, \theta_1) = \begin{cases} \theta_{11}x + \theta_{12}x^2 + \theta_{13}x^3 \\ \theta_{11}\exp(\theta_{12}x) \\ etc \end{cases}$$

- ❹  $\epsilon_t(0), \epsilon_t(1)$  é iid valor extremo

- 1o. estágio: estimar a probabilidade de transição entre os estados,  $p(x_{t+1}|x_t, i_t, \theta_3)$
- 2o. estágio: usa  $\hat{\theta}_3$  e estima  $P(i_t|x_t, \theta)$ .
- Estima a full likelihood

- Tabelas V e VI: resultados do 1o. estágio.
- Estima grupos 1, 2 e 3 juntos.
- Tabela VII: milhagem segue um processo de markov?
- Tabela VIII: procurando a melhor especificação. Escolhe grupos 1, 2 e 3, e custo linear e raiz quadrada.

# Resultados - otimizador versus míope

- Tabela IX: parâmetros estruturais. Usa  $\beta = 0.99$  e  $\beta = 0$  (modelo míope).
- Note a diferença no  $\theta_{11}$ .
- Modelo míope troca o motor somente quando  $c(x, \theta_{11}) > RC + c(0, \theta_{11})$ . Entende que o custo cresce mais rápido com  $x_t$ .



# Resultados - custos

- Custo de retífica para os grupos 1, 2 e 3 é \$9499 (tabela 3). Custo estimado é  $RC = 11.72$ .
- Relação entre real e estimado é  $\sigma = \frac{9499}{11.72}$
- $c(x) = 0.001\theta_{11}x$
- custo estimado é  $\sigma * 0.001 * 4.826 = 3.75$  dolares em manutenção por cada 5000 milhas para os ônibus dos grupos 1, 2 e 3.
- um ônibus com 300,000 milhas tem um custo mensal de 225 dólares maior que um 0 milhas.
- esse custo é 1.70 dolares para ônibus do grupo 4. Isso explica porque os ônibus mais novos dos grupos 1, 2 e 3 retificam o motor mais cedo.